

Scouting Intelligence


Sistema de decision-support para scouting y reclutamiento — FIFA World Cup 2022

Daniela González · Football Data & Insights

Pipeline reproducible que va de los eventos crudos de StatsBomb Open Data a una capa de decisión de scouting: **233 jugadores** del Mundial 2022 perfilados con métricas per-90, embeddings de estilo, roles descubiertos por datos, un modelo bayesiano de finishing y una shortlist multi-criterio. El criterio rector es comunicar la incertidumbre en vez de esconderla: cuando un modelo no aprende o un resultado es nulo, eso también es un hallazgo.

Roles y espacio latente de jugadores

Sobre la feature matrix per-90 estandarizada se aprende un espacio latente con **PCA** como baseline y un **autoencoder no-lineal** en PyTorch. Ambos coinciden, lo que da confianza en que la representación captura estilo de juego real y no artefactos del modelo. Sobre ese latente, un **Gaussian Mixture Model** descubre seis roles por datos —central constructor, lateral/volante mixto, arquero, creador ofensivo, atacante finalizador y volante defensivo— sin imponer la posición nominal.



Mapa de jugadores (UMAP sobre el autoencoder), coloreado por rol. Los arqueros se separan por completo; los jugadores de campo forman un gradiente continuo de defensa a ataque con fronteras difusas.

Motor de similitud de scouting

Dado un jugador de referencia, el motor devuelve los más parecidos por **similitud coseno sobre el espacio latente de 8 dimensiones** (no sobre la proyección 2D). Para el perfil de Otamendi, siete de ocho vecinos son centrales de selecciones distintas con similitud 0.92–0.96: el estilo, no la etiqueta, define el match. Aparecen además nombres con menos minutos (Alderweireld, Christensen) —candidatos menos expuestos— y casos como Molina o Rice, que capturan la función defensiva real más allá de la posición nominal.

Más similares a Otamendi (DEF)

Jugador	Selección	Min	Similitud
Dejan Lovren	Croatia	635	0.961
Toby Alderweireld	Belgium	286	0.950
Nathan Aké	Netherlands	515	0.938
Andreas Christensen	Denmark	293	0.934
Éder Gabriel Militão	Brazil	364	0.934
Nahuel Molina Lucero	Argentina	595	0.923

Jugador	Selección	Min	Similitud
Ko Itakura	Japan	294	0.921
Declan Rice	England	452	0.921


Más similares a Messi (FW) — segundo ejemplo

Jugador	Selección	Min	Similitud
Salem Mohammed Al Dawsari	Saudi Arabia	300	0.948
Neymar da Silva Santos Junior	Brazil	285	0.931
Kylian Mbappé Lottin	France	660	0.929
Christian Pulisic	United States	338	0.922
Vinícius José Paixão de Oliveira Júnior	Brazil	305	0.908
Daniel Olmo Carvajal	Spain	390	0.902
Heung-Min Son	South Korea	390	0.887
João Félix Sequeira	Portugal	340	0.885

El mismo motor generaliza de un central a un delantero sin recalibración: para Messi devuelve extremos y enganches (Al Dawsari, Neymar, Mbappé, Vinícius), perfiles ofensivos coherentes.

Finishing bayesiano — el diferenciador

Una tasa cruda de goles/xG engaña con muestras chicas. El finishing se modela como un **Poisson jerárquico con partial pooling** en PyMC (reparametrización no-centrada para resolver el funnel); el multiplicador indica si un jugador rinde por encima o por debajo de su xG, con shrinkage hacia la media de la liga proporcional al tamaño de muestra. El muestreo convergió correctamente ($\hat{r} = 1.0$, ess en miles).



Multiplicador de finishing posterior con intervalo de credibilidad del 94%. La línea punteada marca el rendimiento esperado por xG.

Si rankeáramos por goles/xG crudo, Mbappé, Julián Álvarez y Lautaro parecerían finalizadores de élite del Mundial. Pero los intervalos de credibilidad de los 22 jugadores cruzan el 1.0 **sin excepción**: con datos de un solo torneo no se puede afirmar que alguien finalice mejor que lo esperado. Un club que paga sobreprecio por el “killer instinct” de un goleador de Mundial está comprando varianza, no habilidad.

Embeddings de grafo de pases — dos nociones de similitud

Sobre la red de pases por equipo se aprenden embeddings de nodo con **node2vec** y con un **Graph Autoencoder (encoder GCN)** implementado desde cero en PyTorch puro. El GCN-GAE no logró estructura aprendible: en un grafo de 32 componentes casi completamente conectadas de ~10 nodos no hay señal de link prediction intra-equipo. Lo diagnosticué en secuencia —nodos sin features, luego negative sampling— y adopté node2vec, más apropiado para esa topología fragmentada. La comparación deja una lección de modelado: **“similar” depende de la representación.**

STATS — perfil de producción (cross-team)

Jugador	Selección	Sim.
Dejan Lovren	Croatia	0.961
Toby Alderweireld	Belgium	0.950
Nathan Aké	Netherlands	0.938
Andreas Christensen	Denmark	0.934
Éder Gabriel Militão	Brazil	0.934
Nahuel Molina Lucero	Argentina	0.923

NODE2VEC — rol estructural en la red de pases

Jugador	Selección	Sim.
Leandro Daniel Paredes	Argentina	0.984
Lautaro Javier Martínez	Argentina	0.980
Germán Alejandro Pezzella	Argentina	0.977
Gonzalo Ariel Montiel	Argentina	0.977
Guido Rodríguez	Argentina	0.977
Julián Álvarez	Argentina	0.976

Para Otamendi, los embeddings de producción devuelven centrales de cinco países con perfil equivalente (la respuesta correcta para scouting de reemplazos); los estructurales devuelven a sus compañeros de selección (pertenencia a la misma red de circulación, no rol).

Capa de decisión — shortlist y one-pager


La shortlist combina **fit de estilo** (50%), **juventud** (30%, inactiva sin edad en Open Data) y **certeza por tamaño de muestra** (20%). Para el perfil de Otamendi devuelve un ranking creíble de centrales de élite.

Shortlist para el perfil de Otamendi

Jugador	Selección	Min	Fit	Score
Joško Gvardiol	Croatia	732	0.914	0.829
Dejan Lovren	Croatia	635	0.961	0.808
Nahuel Molina Lucero	Argentina	595	0.923	0.774
Cristian Gabriel Romero	Argentina	581	0.882	0.750
Nathan Aké	Netherlands	515	0.938	0.746
Dayotchanculle Upamecano	France	523	0.912	0.738
Josip Juranović	Croatia	635	0.800	0.736
Achraf Hakimi Mouh	Morocco	665	0.762	0.732
Virgil van Dijk	Netherlands	520	0.885	0.724
Daley Blind	Netherlands	456	0.909	0.708

Jugador	Selección	Min	Fit	Score
Raphaël Varane	France	544	0.813	0.702
Rúben Santos Gato Alves Dias	Portugal	396	0.906	0.680

El primero no es el de mayor similitud, sino el que mejor combina fit y protagonismo: **Joško Gvardiol**, 20 años, fichado por ~90M meses después. El modelo lo detectó solo con datos de eventos, sin edad ni valor de mercado: el caso de uso central del scouting basado en datos.



One-pager exportable: radar de percentiles más ficha con incertidumbre bayesiana.

Análisis táctico — ¿quién absorbe las funciones de Messi?

El mismo perfil de percentiles permite descomponer las funciones de un jugador en su plantel. Mac Allister hereda buena parte de la creación y el volumen de pase; Julián Álvarez concentra la presión y el juego sin pelota. Ninguno reproduce el perfil completo: las funciones se reparten.



Notas de metodología y reproducibilidad

Los minutos se estiman desde el Starting XI y las sustituciones (se ignoran expulsiones, está documentado). La dimensión de edad queda neutra porque Open Data no trae fecha de nacimiento fiable, y se activa sola al cambiar a una fuente licenciada. La capa de ingesta está desacoplada: apuntar a la API completa de StatsBomb o a SkillCorner solo requiere reemplazar la función de descarga, sin tocar el resto del pipeline. Todo el sistema usa seeds fijas (PCA/AE, GMM, UMAP, PyMC, node2vec).